BPMS - Process Mining I

Prof. Dr. Andreas Hense
andreas.hense@h-brs.de

Wirtschaftsinformatik

Hochschule
Bonn-Rhein-Sieg
University of Applied Sciences

Agenda I

1. Einführung
   - Der Nutzen von Prozessmodellen
   - Beispielprozess mit Log
2. Vorgehen beim Process Mining
   - ETL
   - eXtensible Event Streams
3. ProM
4. Der Alpha-Algorithmus
5. Qualitätskriterien
6. Literatur

Einführung

Der Nutzen von Prozessmodellen

Wir folgen [Aal11a] bzw. [Aal11b]

Erkenntnis Der Modellierer wird angeregt, den Prozess von mehreren Seiten zu betrachten.

Diskussion Die verschiedenen Beteiligten (Stakeholder) nutzen Modelle, um ihre Diskussion zu strukturieren.

Dokumentation Prozesse werden dokumentiert, um Mitarbeiter auszubilden oder für Zertifizierungen (z. B. ISO 9000).

Verifikation Prozessmodelle werden analysiert um Fehler in Systemen zu finden (z. B. Deadlocks).

Performance Analyse Simulation kann genutzt werden, um Antwortzeitverhalten oder Service Level zu verstehen.

Animation Nutzer können mit Modellen "spielen" und dem Designer Feedback geben.

Spezifikation Modelle können PAIS (process aware information system) vor ihrer Implementierung beschreiben und als "Vertrag" zwischen Entwickler und Anwender dienen.

Konfiguration Modelle können benutzt werden, um Systeme zu konfigurieren.

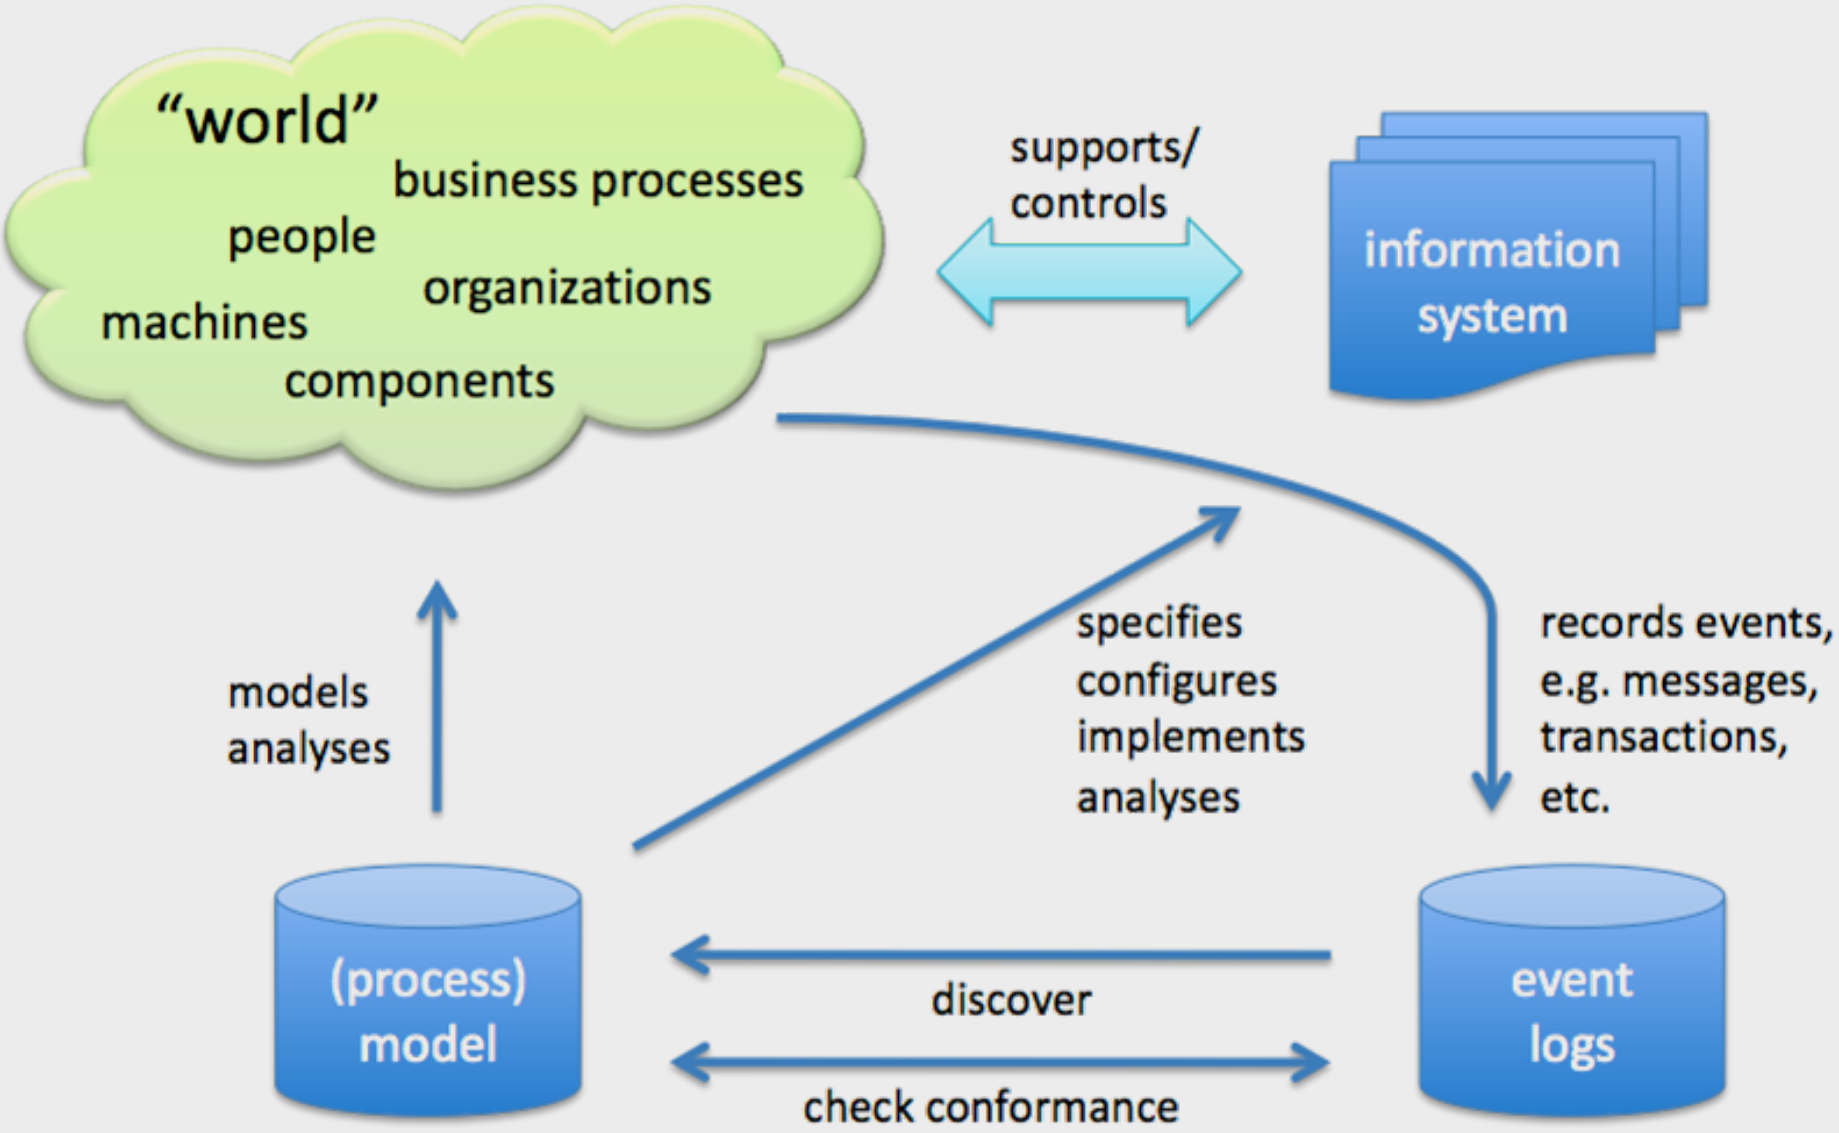
"world"
business processes
people
organizations
machines
components
supports/
controls
information
system
models
analyses
specifies
configures
implements
analyses
records events,
e.g. messages,
transactions,
etc.
(process)
model
discover
check conformance
event
logs

[AAHR09]

Einführung

Beispielprozess mit Log

Beispielprozessmodell Petrinetz

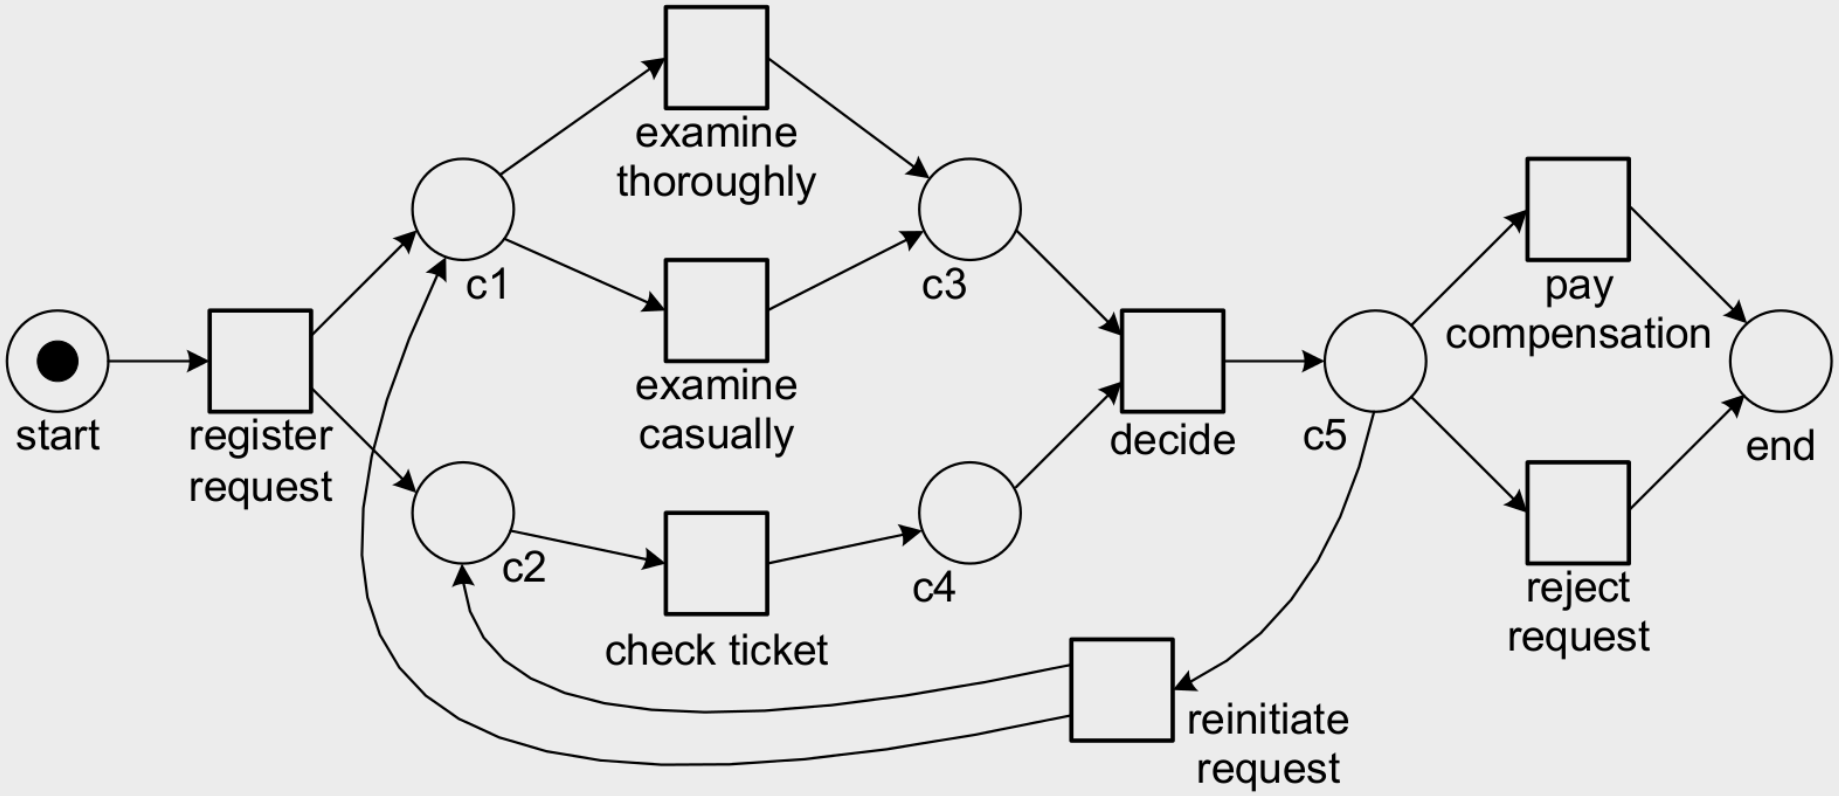

[Aal16]

Live Feedback

- Welche Eigenschaften hat das Beispielprozessmodell Petrinetz?

Beispielprozessmodell BPMN

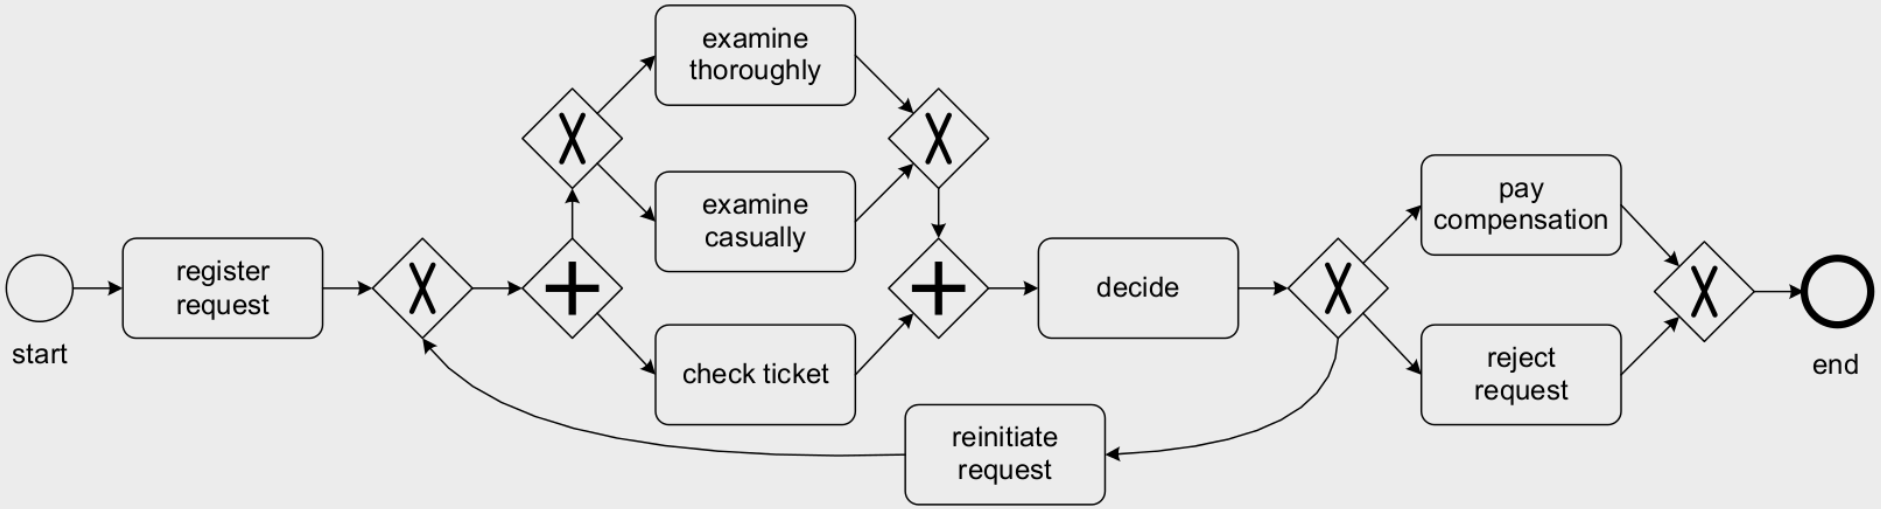

[Aal16]

Event Log

1	35654423	30-12-2010:11.02	register request	Pete	50	...
	35654424	31-12-2010:10.06	examine thoroughly	Sue	400	...
	35654425	05-01-2011:15.12	check ticket	Mike	100	...
	35654426	06-01-2011:11.18	decide	Sara	200	...
	35654427	07-01-2011:14.24	reject request	Pete	200	...
2	35654483	30-12-2010:11.32	register request	Mike	50	...
	35654485	30-12-2010:12.12	check ticket	[illegible]	[illegible]	
	35654487	30-12-2010:14.16	examine casually			
	35654488	05-01-2011:11.22	decide			
	35654489	08-01-2011:12.05	pay compensation			
3	35654521	30-12-2010:14.32	register request			
	35654522	30-12-2010:15.06	examine casually			
	35654524	30-12-2010:16.34	check ticket			
	35654525	06-01-2011:09.18	decide			
	35654526	06-01-2011:12.18	reinitiate request			
	35654527	06-01-2011:13.06	examine thoroughly			
	35654530	08-01-2011:11.43	check ticket			
	35654531	09-01-2011:09.55	decide			
	35654533	15-01-2011:10.45	pay compensation			
4	35654641	06-01-2011:15.02	register request			
	35654643	07-01-2011:12.06	check ticket			
	35654644	08-01-2011:14.43	examine thoroughly			
	35654645	09-01-2011:12.02	decide			
	35654647	12-01-2011:15.44	reject request			
5	35654711	06-01-2011:09.02	register request			
	35654712	07-01-2011:10.16	examine casually			
	35654714	08-01-2011:11.22	check ticket			
	35654715	10-01-2011:13.28	decide			
	35654716	11-01-2011:16.18	reinitiate request			
	35654718	14-01-2011:14.33	check ticket			
	35654719	16-01-2011:15.50	examine casually			
	35654720	19-01-2011:11.18	decide	Sara	200	...
	35654721	20-01-2011:12.48	reinitiate request	Sara	200	...
	35654722	21-01-2011:09.06	examine casually	Sue	400	...
	35654724	21-01-2011:11.34	check ticket	Pete	100	...
	35654725	23-01-2011:13.12	decide	Sara	200	...
	35654726	24-01-2011:14.56	reject request	Mike	200	...
6	35654871	06-01-2011:15.02	register request	Mike	50	...
	35654873	06-01-2011:16.06	examine casually	Ellen	400	...
	35654874	07-01-2011:16.22	check ticket	Mike	100	...

case id	event id	properties				
		timestamp	activity	resource	cost	...
1	35654423	30-12-2010:11.02	register request	Pete	50	...
	35654424	31-12-2010:10.06	examine thoroughly	Sue	400	...
	35654425	05-01-2011:15.12	check ticket	Mike	100	...
	35654426	06-01-2011:11.18	decide	Sara	200	...
	35654427	07-01-2011:14.24	reject request	Pete	200	...
2	35654483	30-12-2010:11.32	register request	Mike	50	...
	35654485	30-12-2010:12.12	check ticket	Mike	100	...
	35654487	30-12-2010:14.16	examine casually	Pete	400	...
	35654488	05-01-2011:11.22	decide	Sara	200	...
	35654489	08-01-2011:12.05	pay compensation	Ellen	200	...

XES, CSV, etc.

[Aal16]

Vereinfachter Event Log

case id	event id	properties				
		timestamp	activity	resource		
1	35654423	30-12-2010:11.02	register request	Pete		
	35654424	31-12-2010:10.06	examine thoroughly	Sue		
	35654425	05-01-2011:15.12	check ticket	Mike		
	35654426	06-01-2011:11.18	decide	Sara		
	35654427	07-01-2011:14.24	reject request	Pete		
2	35654483	30-12-2010:11.32	register request	Mike		
	35654485	30-12-2010:12.12	check ticket	Mike		
	35654487	30-12-2010:14.16	examine casually	Pete		
	35654488	05-01-2011:11.22	decide	Sara		
	35654489	08-01-2011:12.05	pay compensation	Ellen		
3	35654521	30-12-2010:14.32	register request	Pete		
	35654522	30-12-2010:15.06	examine casually	Mike		
	35654524	30-12-2010:16.34	check ticket	Ellen		
	35654525	06-01-2011:09.18	decide	Sara		
	35654526	06-01-2011:12.18	reinitiate request	Sara		
	35654527	06-01-2011:13.06	examine thoroughly	Sean		
	35654530	08-01-2011:11.43	check ticket	Pete		
	35654531	09-01-2011:09.55	decide	Sara		
	35654533	15-01-2011:10.45	pay compensation	Ellen		
4	35654641	06-01-2011:15.02	register request	Pete	50	...
	35654643	07-01-2011:12.06	check ticket	Mike	100	...
	35654644	08-01-2011:14.43	examine thoroughly	Sean	400	...
	35654645	09-01-2011:12.02	decide	Sara	200	...
	35654647	12-01-2011:15.44	reject request	Ellen	200	...
5	35654711	06-01-2011:09.02	register request	Ellen	50	...
	35654712	07-01-2011:10.16	examine casually	Mike	400	...
	35654714	08-01-2011:11.22	check ticket	Pete	100	...
	35654715	10-01-2011:13.28	decide	Sara	200	...
	35654716	11-01-2011:16.18	reinitiate request	Sara	200	...
	35654718	14-01-2011:14.33	check ticket	Ellen	100	...
	35654719	16-01-2011:15.50	examine casually	Mike	400	...
	35654720	19-01-2011:11.18	decide	Sara	200	...
	35654721	20-01-2011:12.48	reinitiate request	Sara	200	...
	35654722	21-01-2011:09.06	examine casually	Sue	400	...
	35654724	21-01-2011:11.34	check ticket	Pete	100	...
	35654725	23-01-2011:13.12	decide	Sara	200	...
	35654726	24-01-2011:14.56	reject request	Mike	200	...
6	35654871	06-01-2011:15.02	register request	Mike	50	...
	35654873	06-01-2011:16.06	examine casually	Ellen	400	...
	35654874	07-01-2011:16.22	check ticket	Mike	100	...
	35654875	07-01-2011:16.52	decide	Sara	200	...
	35654877	16-01-2011:11.47	pay compensation	Mike	200	...

case id	trace
1	$\langle a,b,d,e,h \rangle$
2	$\langle a,d,c,e,g \rangle$
3	$\langle a,c,d,e,f,b,d,e,g \rangle$
4	$\langle a,d,b,e,h \rangle$
5	$\langle a,c,d,e,f,d,c,e,f,c,d,e,h \rangle$
6	$\langle a,c,d,e,g \rangle$
...	...

a = register request,
b = examine thoroughly,
c = examine casually,
d = check ticket,
e = decide,
f = reinitiate request,
g = pay compensation,
and h = reject request

[Aal16]

Process Discovery

case id	trace
1	$\langle a,b,d,e,h \rangle$
2	$\langle a,d,c,e,g \rangle$
3	$\langle a,c,d,e,f,b,d,e,g \rangle$
4	$\langle a,d,b,e,h \rangle$
5	$\langle a,c,d,e,f,d,c,e,f,c,d,e,h \rangle$
6	$\langle a,c,d,e,g \rangle$
...	...

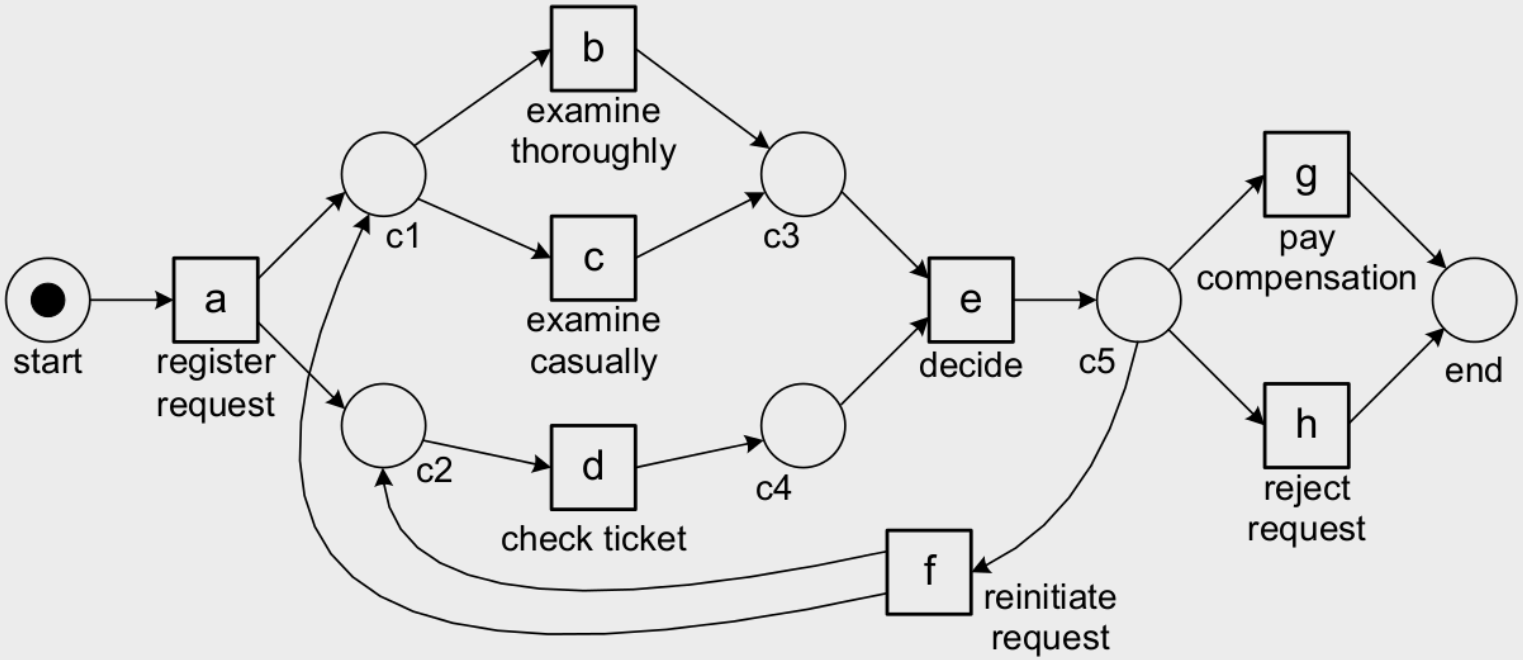

[Aal16]

Process Discovery mit weniger Events

$$\{\langle a,b,d,e,h\rangle, \langle a,d,b,e,h\rangle\}$$

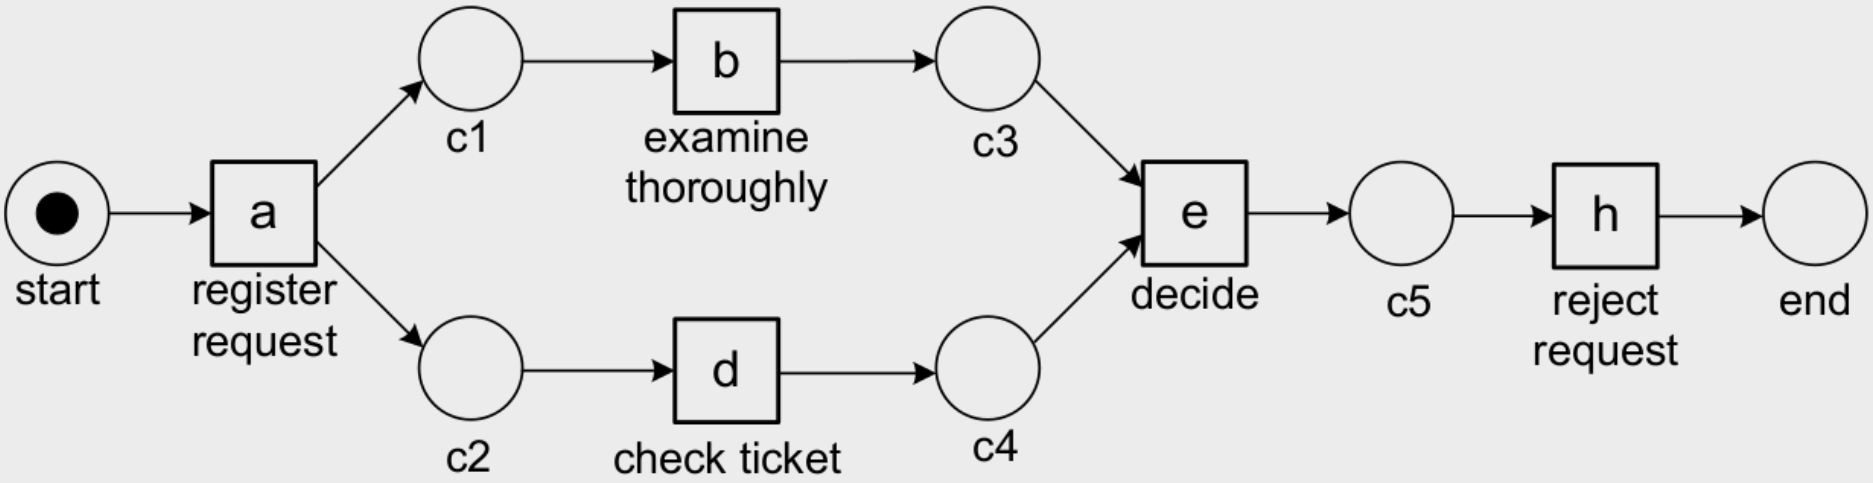

[Aal16]

Vorgehen beim Process Mining

ETL

Datenquellen für Process Mining I

- Im allgemeinen Fall kommen die Daten für das Process Mining aus verschiedenen Systemen und liegen in unterschiedlichen Formaten vor.
- Häufig muss man bei Standardsoftware (z. B. ERP Systemen) die Informationen aus unterschiedlichen Tabellen einer ggf. nicht offenen Datenbank extrahieren.
- Bei anderen Systemen kann es sein, dass man auf Logdateien im Textformat zugreifen muss.
- Angewandt werden Techniken aus dem Data Warehousing (s. n. Folie).

Process Mining ETL

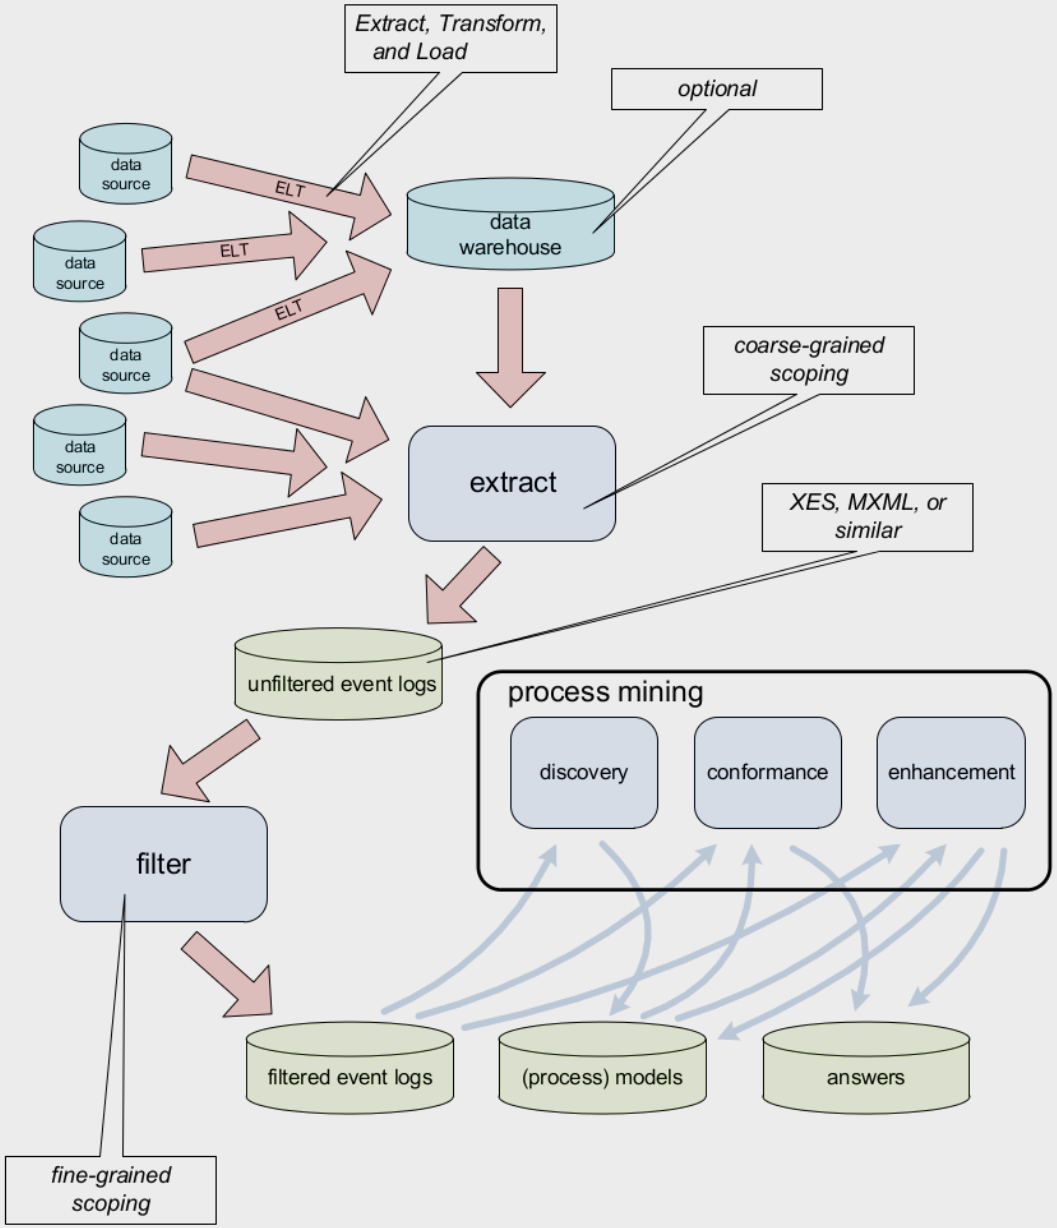

[Aal16]

Vorgehen beim Process Mining

eXtensible Event Streams

XES

- Beim ETL-Prozess wird als Zwischenergebnis ein Format erzeugt, welches von den Process-Mining Werkzeugen weiterverarbeitet werden kann.
- eXtensible Event Stream (XES) [noa16] ist der IEEE-Standard für Prozess-Logs `http://www.xes-standard.org`.
- Ein Log besteht aus mehreren Traces.
- In jedem Trace sind normalerweise die Events eines Case in der historischen Reihenfolge aufgezählt.

XES Metadata Structure

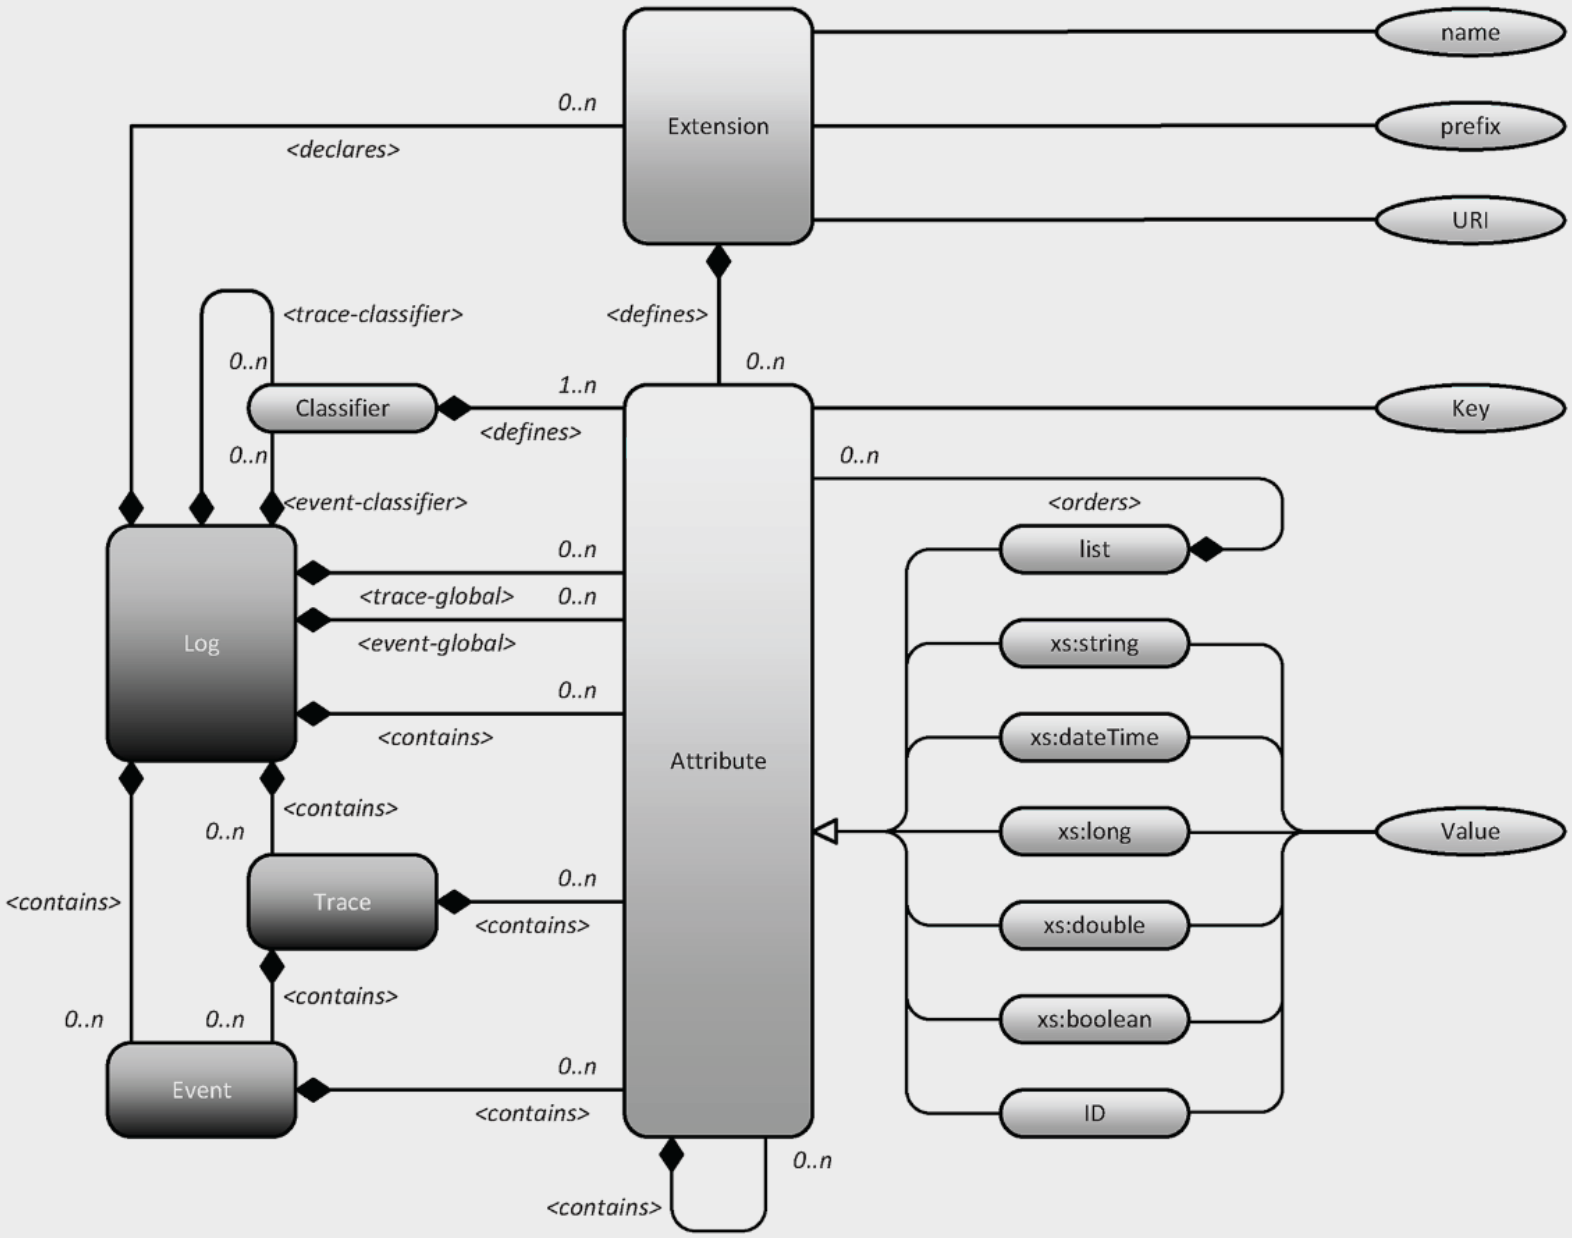

[noa16]

XES

- XES hat ein Zustandsdiagramm, welches sich am Business Process Analytics Format (BPAF) der WfMC orientiert.
- Beim XES-Zustandsdiagramm werden dabei nicht die Zustände von BPAF sondern die Zustandsübergänge als Bezeichner gewählt.
- XES-Beispieldatei:
  `../promExperimente/201312ProblemMgmtWorkshop/ProblemManagementAmEndeGefiltertEditModified.xes`

XES Zustandsdiagramm

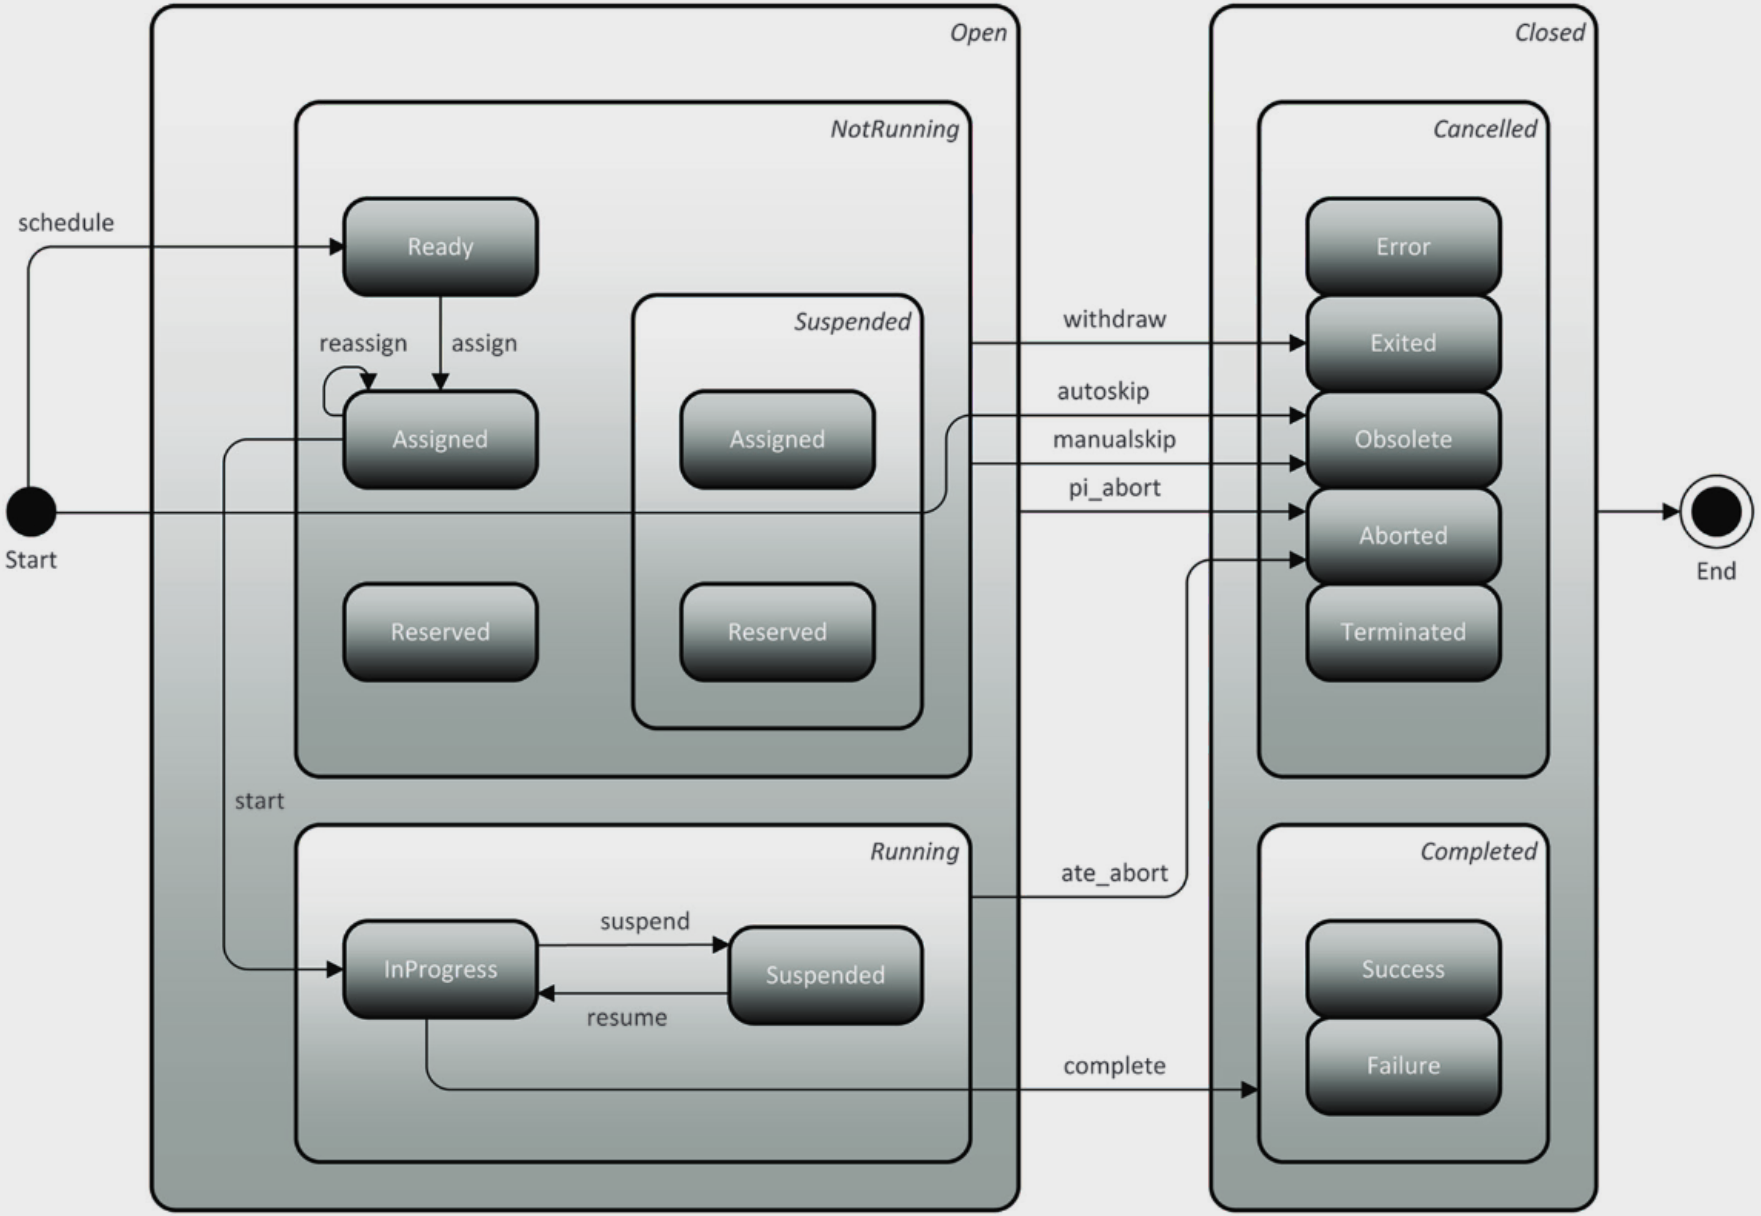

[noa

Live Feedback

- In welcher Reihenfolge von der Größe her absteigend sind die Elemente in XES angeordnet?
- In welcher Sprache sind XES-Logs geschrieben?

Resources

Forum `http://www.win.tue.nl/promforum/`

Documentation Mit dieser Übersicht `http://www.promtools.org/doku.php?id=packdocs` kommt man zu diesem Trac `https://svn.win.tue.nl/trac/prom/browser/Documentation`

Package Overview Mit dem Plugin "Show Package Overview" erhält man eine Übersicht über alle installierten Packages und ihre Abhängigkeiten.

Demo mit YAWL Prozess I

XES Die YAWL Engine erzeugt XES (eXtensible Event Stream). Beispiel siehe Datei `../promExperimente/201312ProblemMgmtWorkshop/ProblemManagementAmEndeGefiltertEditModified.xes`

Problem Management Prozess Der Prozess wurde im Rahmen einer Übung mehrfach ausgeführt.

Laden in ProM starte ProM62.sh; import `ProblemManagementAmEndeGefiltertEditModified.xes`

Betrachten Reiter mit "Auge", dort Dashboard, Inspector, Summary

Zeitliche Aspekte Dotted Chart

Process Discovery Reiter mit "Play", dort "Mine for a Petri net using ILP"

Demo mit YAWL Prozess II

Wer arbeitet mit wem? Reiter mit "Auge", dort "Mine for Working together social network"

Zur Kontrolle: der YAWL Prozess Problem Mgmt

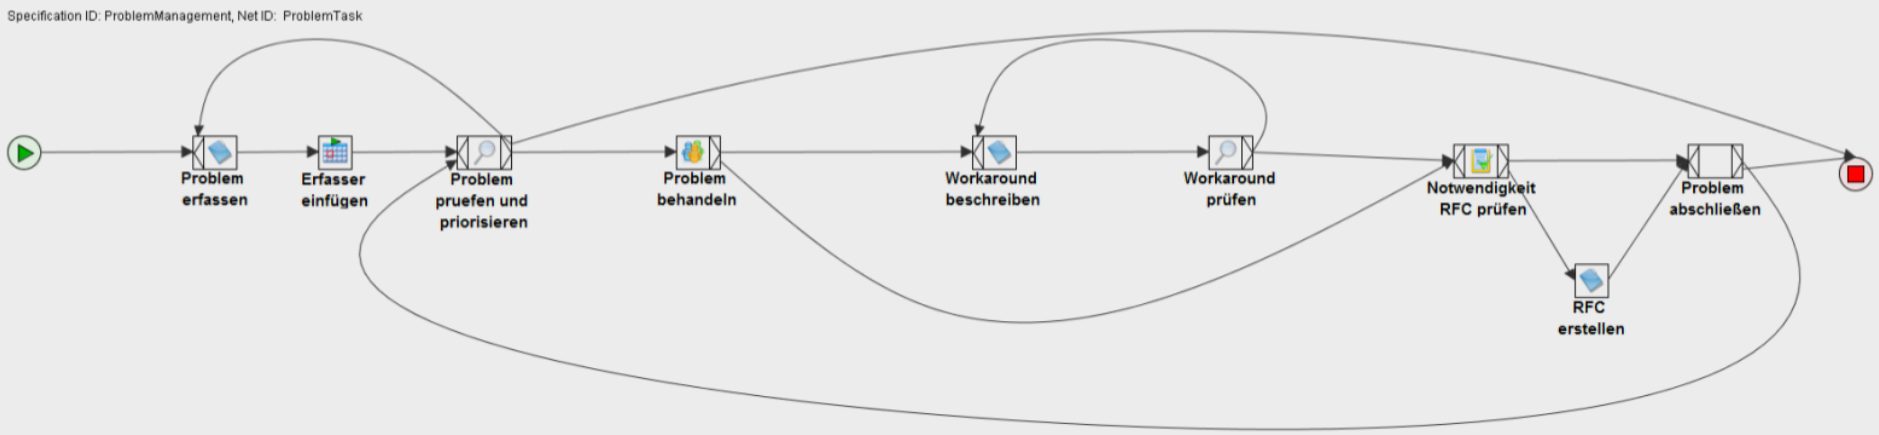

Der α-Algorithmus ist ein leicht zu erklärendes Verfahren, welches die Grundlage für viele der in der Praxis eingesetzten Algorithmen ist. Wir folgen [Aal16].

Definition

Ein Event Log L über einer Menge von Transitionen T ist eine Abbildung $L : T^* \to \mathbb{N}$.

Live Feedback

- Welcher Begriff ist bei Petrinetzen ein Element von T^*?

Der α-Algorithmus erzeugt aus einem Event Log ein Workflow-Netz: $\alpha(L) = N$ mit der Anfangsmarkierung $M = i$.

Definition

Log-basierte Ordnungsrelationen: Sei L ein Event Log über einer Menge von Transitionen T und $a, b \in T$:

$a >_L b$ gdw $\exists \sigma = \langle t_1, \ldots, t_n \rangle$ und $i \in \{1, \ldots, n-1\}$, so dass $\sigma \in L$ und $t_i = a$ und $t_i + 1 = b$, "folgt direkt"

$a \rightarrow_L b$ gdw $a >_L b$ und $b \not>_L a$, "Sequenz"

$a \#_L b$ gdw $a \not>_L b$ und $b \not>_L a$, "unabhängig"

$a \|_L b$ gdw $a >_L b$ und $b >_L a$, "parallel"

Aufgabe an Tafel

Erstellen Sie die Ordnungsrelationen für
$L_1 = [\langle a, b, c, d \rangle^3, \langle a, c, b, d \rangle^2, \langle a, e, d \rangle]$
(`.../promExperimente/ArtificialLogs/L1.xes`)

Lösung

$$
\begin{aligned}
>_{L_1} &= \{(a,b),(a,c),(a,e),(b,c),(c,b),(b,d),(c,d),(e,d)\} \\
\rightarrow_{L_1} &= \{(a,b),(a,c),(a,e),(b,d),(c,d)(e,d)\} \\
\#_{L_1} &= \{(a,a),(a,d),(b,b),(b,e),(c,c),(c,e),(d,a),(d,d), \\
&\qquad (e,b),(e,c),(e,e)\} \\
\|_{L_1} &= \{(b,c),(c,b)\}
\end{aligned}
$$

- Für jeden Event Log L über T und $x, y \in T$: $x \rightarrow_L y, y \rightarrow_L x, x \#_L y$, oder $x \parallel_L y$, d. h. genau eine der Relationen gilt für jedes Paar von Transitionen.
- Daher kann der Fußabdruck eines Event Logs wie L_1 in einer Matrix wie der folgenden dargestellt werden.

	a	b	c	d	e
a	$\#_{L_1}$	$\rightarrow_{L_1}$	$\rightarrow_{L_1}$	$\#_{L_1}$	$\rightarrow_{L_1}$
b	$\leftarrow_{L_1}$	$\#_{L_1}$	$\parallel_{L_1}$	$\rightarrow_{L_1}$	$\#_{L_1}$
c	$\leftarrow_{L_1}$	$\parallel_{L_1}$	$\#_{L_1}$	$\rightarrow_{L_1}$	$\#_{L_1}$
d	$\#_{L_1}$	$\leftarrow_{L_1}$	$\leftarrow_{L_1}$	$\#_{L_1}$	$\leftarrow_{L_1}$
e	$\leftarrow_{L_1}$	$\#_{L_1}$	$\#_{L_1}$	$\rightarrow_{L_1}$	$\#_{L_1}$

Definition

α-Algorithmus: Sei L ein Event Log über T. $\alpha(L)$ ist folgendermaßen definiert:

1. $T_L = \{t \in T \mid \exists_{\sigma \in L}\, t \in \sigma\}$
2. $T_I = \{t \in T \mid \exists_{\sigma \in L}\, t = \mathrm{first}(\sigma)\}$
3. $T_O = \{t \in T \mid \exists_{\sigma \in L}\, t = \mathrm{last}(\sigma)\}$
4. $X_L = \{(A, B) \mid A \subseteq T_L \wedge A \neq \emptyset \wedge B \subseteq T_L \wedge B \neq \emptyset \wedge \forall_{a \in A} \forall_{b \in B}\, a \rightarrow_L b \wedge \forall_{a_1, a_2 \in A}\, a_1 \#_L a_2 \wedge \forall_{b_1, b_2 \in B}\, b_1 \#_L b_2\}$
5. $Y_L = \{(A, B) \in X_L \mid \forall_{(A', B') \in X_L}\, A \subseteq A' \wedge B \subseteq B' \Longrightarrow (A, B) = (A', B')\}$
6. $P_L = \{p_{(A,B)} \mid (A, B) \in Y_L\} \cup \{i_L, o_L\}$
7. $F_L = \{(a, p_{(A,B)}) \mid (A, B) \in Y_L \wedge a \in A\} \cup \{(p_{(A,B)}, b) \mid (A, B) \in Y_L \wedge b \in B\} \cup \{(i_L, t) \mid t \in T_I\} \cup \{(t, o_L) \mid t \in T_O\}$
8. $\alpha(L) = (P_L, T_L, F_L)$

- $p_{(A,B)}$ ist eine Stelle unseres Netzes mit $\bullet p_{(A,B)} = A$ und $p_{(A,B)}\bullet = B$.

Aufgabe an Tafel

Wenden Sie den α-Algorithmus auf
$L_1 = [\langle a, b, c, d\rangle^3, \langle a, c, b, d\rangle^2, \langle a, e, d\rangle]$ an.

- Einige Probleme des α-Algorithmus:
  - Er produziert nicht immer korrekte Workflow-Netze.
  - Er kann nicht mit Zyklen der Länge 1 und 2 umgehen.
  - Er berücksichtigt Häufigkeiten in Event Logs nicht.

Übung in Vorlesung: α-Algorithmus

Wenden Sie den α-Algorithmus auf den folgenden Log an.
$L_{12} = [\langle a, b, c\rangle^{10}, \langle a, c, d\rangle^2, \langle a, b, c, d\rangle]$

Live Feedback

- Wie viele Stellen hat Ihr Petrinetz?

Übung zu Hause: α-Algorithmus

Wenden Sie den α-Algorithmus auf den folgenden Log an.
$L_{13} = [\langle a, c, d, f \rangle^{15}, \langle b, c, d, f \rangle^{12}, \langle a, c, d, e, c, d, f \rangle^{5}, \langle b, c, d, e, c, d, f \rangle^{3}, \langle a, c, d, e, c, d, e, c, d, f \rangle,]$

Qualitätskriterien I

- Man kann nicht erwarten, das Originalprozessmodell zu finden.
- Jedes Petrinetz definiert die Sprache aller seiner Feuersequenzen.
- Diese Sprache kann eine unendliche Menge sein – ein Event Trace ist aber immer endlich.
- Bei der Process Discovery muss man demnach heuristisch vorgehen und ein möglichst passendes Modell nach folgenden Kriterien suchen:
- **Fitness** Das Modell sollte das Verhalten im Event Log ermöglichen.
  Precision Das Modell sollte kein Verhalten ermöglichen, welches zu dem Event Log sehr unterschiedlich ist.
  Generalization Das Modell sollte Verhalten ähnlich zum Event Log ermöglichen.
  Simplicity Das Modell sollte so einfach wie möglich sein.

Qualitätskriterien: Beispiel Log

#	trace
455	acdeh
191	abdeg
177	adceh
144	abdeh
111	acdeg
82	adceg
56	adbeh
47	acdefdbeh
38	adbeg
33	acdefbdeh
14	acdefbdeg
11	acdefdbeg
9	adcefcdeh
8	adcefdbeh
5	adcefbdeg
3	acdefbdefdbeg
2	adcefdbeg
2	adcefbdefbdeg
1	adcefdbefbdeh
1	adbefbdefdbeg
1	adcefdbefcdefdbeg
1391	

[Aal16] .../Quellen/ProcessMining2016VanderAalst/event-logs-process-mining-book/Chapter_7/Lfull.xes

Qualitätskriterien: Netz 1 [Aal16]

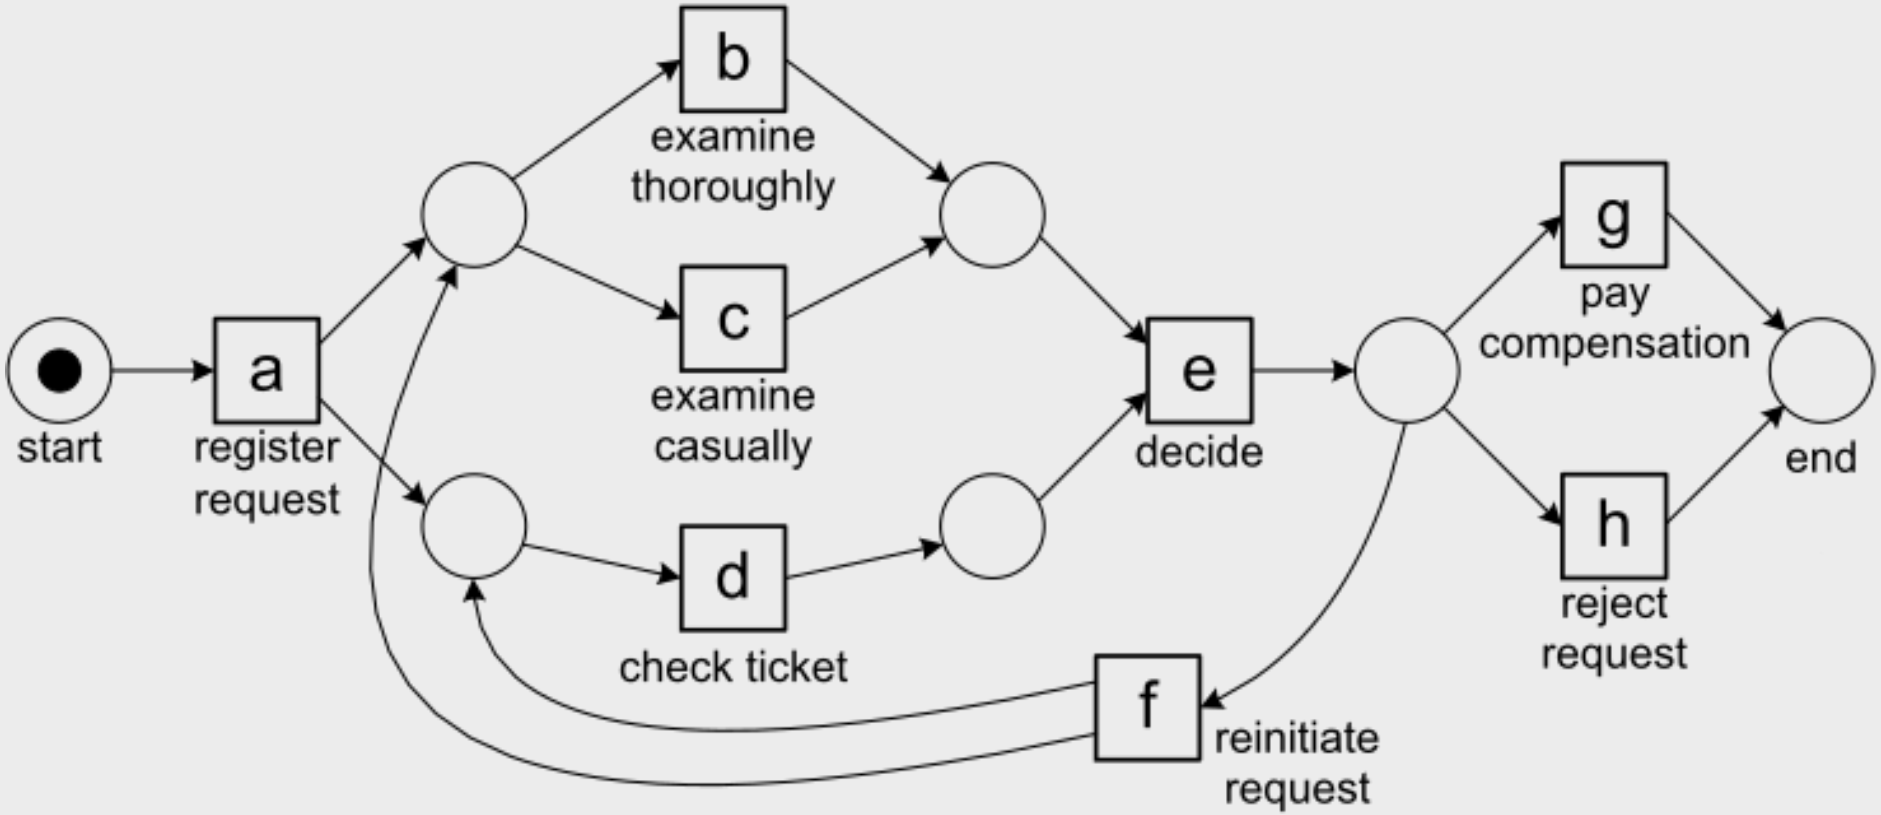

Live Feedback

- Welche Qualitätskriterien werden von Netz 1 erfüllt?

Qualitätskriterien: Netz 2 [Aal16]

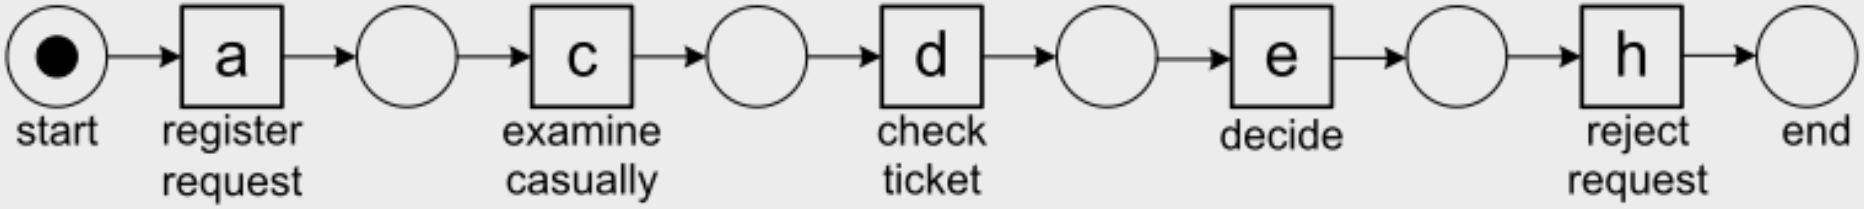

Live Feedback

- Welche Qualitätskriterien werden von Netz 2 erfüllt?

Qualitätskriterien: Netz 3 [Aal16]

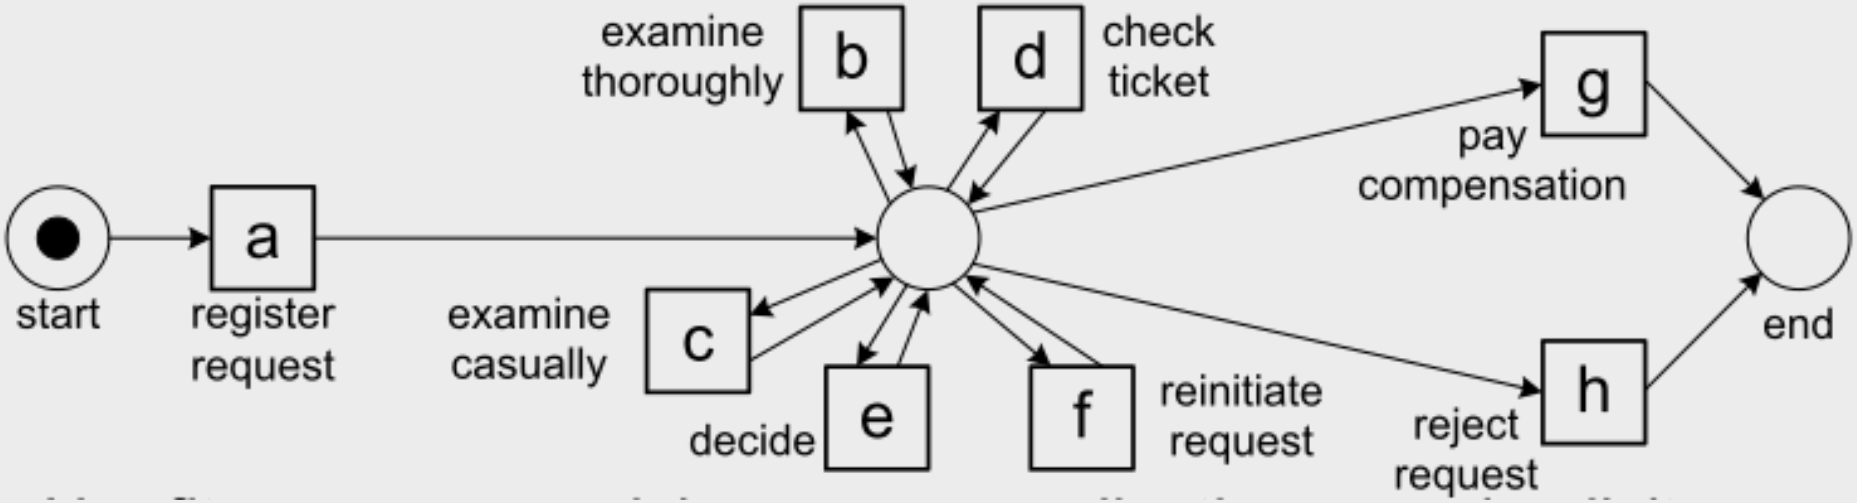

Live Feedback

- Welche Qualitätskriterien werden von Netz 3 erfüllt?

Qualitätskriterien: Netz 4 [Aal16]

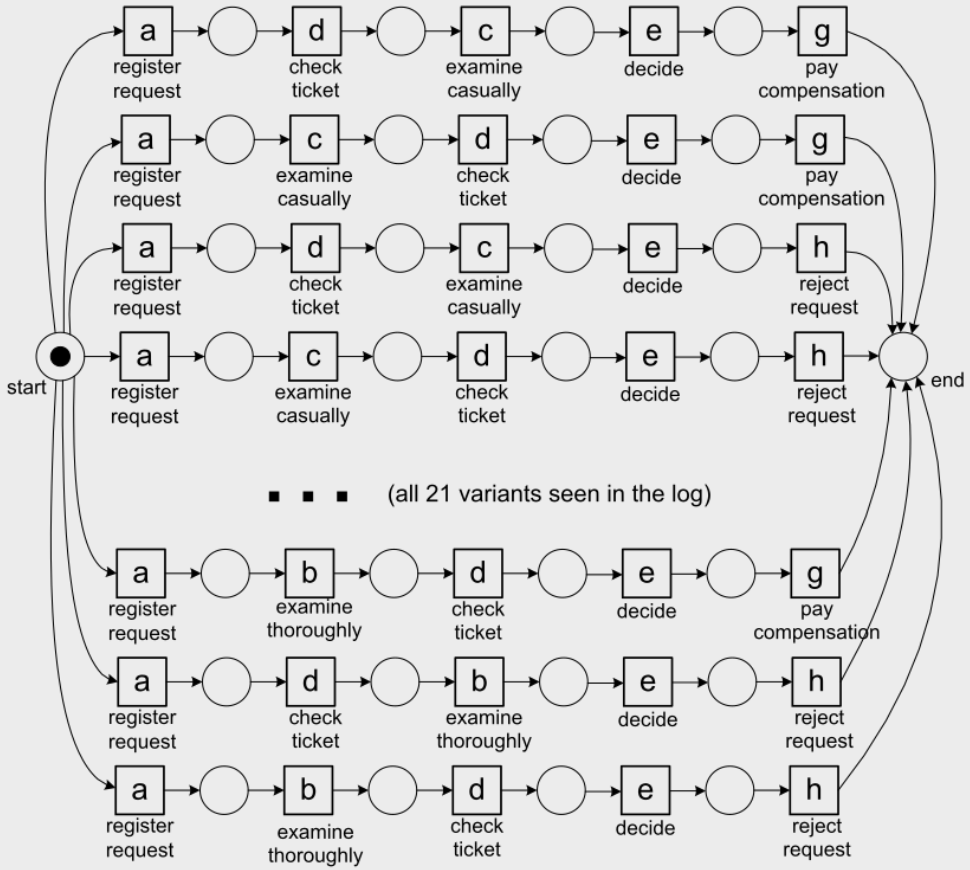

Live Feedback

- Welche Qualitätskriterien werden von Netz 4 erfüllt?

Literatur I

Aalst, Wil van d. ; Adams, Michael ; Hofstede, Arthur ter ; Russel, Nick:
YAWL.
www.yawlfoundation.org.
Version: 2009

Aalst, W. M. P. d.:
Process mining: discovery, conformance and enhancement of business processes.
Berlin : Springer, 2011. –
ISBN 3–642–19344–7 978–3–642–19344–6 978–3–642–19345–3 3–642–19345–5

Literatur II

AALST, Wil van d.:
Process Mining Discovery, Conformance and Enhancement of Business Processes.
Version: 2011.
http://www.processmining.org/blogs/pre2011/slides_supporting_the_process_mining_book

AALST, Wil M. P. van d.:
Process Mining: Data Science in Action.
2nd ed. 2016.
New York, NY : Springer, 2016. –
ISBN 978–3–662–49850–7

Literatur III

IEEE Standard for eXtensible Event Stream (XES) for Achieving Interoperability in Event Logs and Event Streams.
In: *IEEE Std 1849-2016* (2016), November, S. 1–50.
http://dx.doi.org/10.1109/IEEESTD.2016.7740858. – DOI 10.1109/IEEESTD.2016.7740858

Hinweise zur Nutzung dieses Foliensatzes

Dieser Foliensatz wird ausschließlich den Teilnehmern dieser Lehrveranstaltung zur Verfügung gestellt. Er dient als Hilfe für die Vor- und Nachbereitung der Inhalte der Lehrveranstaltung und zur Prüfungsvorbereitung. Für diese Zwecke darf eine lokale Kopie erzeugt werden. Dieser Foliensatz darf nicht an Dritte weitergegeben werden.

© Andreas V. Hense 2025